

EnergyCast-App

Stündliche Lastprognose für Deutschland mit dem QUA³CK-Prozessmodell.

Name	Niklas Schneider
Matrikelnummer	...
Modul	... - Data Analytics und Big Data
Präsentationsdatum	03.08.2026
Github-Repo	NiklasSkulll/EnergyCast-App

Projektüberblick und Forschungsfrage

EnergyCast prognostiziert die stündliche nationale Stromlast in Deutschland für 2015-2019.

? Ziel

Prognose der Zielvariable

DE_load_actual_entsoe_transparency in MW.

≤ Kriterium

sMAPE $\leq$ 5% im einmalig verwendeten Testjahr 2019.

→ Produkt

Reproduzierbare Pipeline und Streamlit-Anwendung für Szenarioanalysen.

Q - Question

Die Forschungsfrage wird als überwachtes Zeitreihen-Regressionsproblem formuliert.

- Beobachtungseinheit: eine stündliche Beobachtung der nationalen Last in Deutschland
- Zielvariable: tatsächliche nationale Stromlast in MW
- Prädiktoren: Wetter, erneuerbare Erzeugung, Kalender und historische Last
- Vergleich mit 24-Stunden-Persistenz
- Phase-Q-Notebook: [001_Q_Phase.ipynb](#)



Zentrale Unsicherheit

Der operative Prognosehorizont ist noch nicht vollständig festgelegt.

U - Understanding the Data

Die Datenbasis wird sauber auf Deutschland und den Zeitraum 2015-2019 eingegrenzt.

- OPSD Time Series und OPSD Weather Data als Datengrundlage
- 43,824 stündliche Beobachtungen nach Zusammenführung über `utc_timestamp`
- Keine doppelten UTC-Zeitstempel und keine fehlenden UTC-Stunden
- Lokale Zeit wird nur für Kalendereffekte verwendet







Live-Demo im Notebook

[002_U_Phase.ipynb](#) - "Mean German load by weekday and local hour"

Datenmuster und Datenqualität

Die explorative Analyse zeigt typische Lastmuster und eine belastbare Datenbasis für die Modellierung.

Prädiktorsignal im U-Notebook

load_lag_1h		0.9662
load_lag_168h		0.9105
load_lag_24h		0.7573
DE_temperature		-0.0272

- Höhere Last an Werktagen als an Wochenenden
- Klare tägliche Morgenrampe und Tagesplateau
- Höhere durchschnittliche Last in kälteren Monaten
- Wetterdaten vollständig; kleinere Lücken bei Ziel- und Erneuerbaren-Variablen dokumentiert



Interpretation

Historische Last ist der stärkste Kurzfrist-Prädiktor; Kalender, Wetter und erneuerbare Erzeugung ergänzen den Kontext.

A³ - Algorithmenentwicklung und Optimierung

Feature Engineering folgt der Leakage-Prüfung aus der Datenanalyse (siehe [003_A_Phase.ipynb](#)).

1 Zeitliche Aufteilung

Training: 2015-2017, Validierung: 2018, Test: 2019.

2 Features

22 Features: Kalendermerkmale, Last-Lags, Wetter-Lags und Lags der erneuerbaren Erzeugung.

3 Auswahl

Auswahl über `TimeSeriesSplit` und 2018-sMAPE vor Nutzung des Testjahres.

Leakage-sicheres Evaluationsdesign

Die Modellauswahl bleibt zeitlich strikt vom finalen Testjahr getrennt.

Training

2015-2017

26,135 Modellzeilen

Validierung

2018

Modellauswahl nach sMAPE

Finaler Test

2019

Einmalige Bewertung



Vergangenheitsbasierte Features

Last-, Wetter- und Erneuerbaren-Features werden vor der Nutzung zeitlich verschoben.



Pipeline-Schutz

Imputation und Skalierung werden innerhalb der scikit-learn-Pipelines nur auf Trainingsdaten gelernt.



Testdisziplin

2019 wird erst nach festgelegter Modellwahl und Refit auf 2015-2018 ausgewertet.

Modellvergleich und Modellauswahl

HistGradientBoosting liefert die beste Validierungsleistung und wird vor dem Testjahr 2019 festgelegt.

Kompakter Vergleich auf Basis der dokumentierten Validierungs- und Testmetriken.

Ansatz	2018 Validierung	2019 Test	Rolle
HistGradientBoosting regressor - full lagged feature set	0.7420% sMAPE	0.7566% sMAPE	Final ausgewählt
XGBoost regressor - full lagged feature set	0.7885% sMAPE	0.7769% sMAPE	Bester Vergleichskandidat
Random Forest regressor - full lagged feature set	0.8623% sMAPE	0.8018% sMAPE	Robuste Referenz
24h naive persistence	8.3684% sMAPE	8.4171% sMAPE	Pflicht-Baseline



Live-Demo im Notebook

- [003_A_Phase.ipynb](#) - "2018 validation sMAPE by A-phase regression candidate"
- [003_A_Phase_candidate_model_metadata.json](#) - Werte des besten Modells

C - Conclude & Compare

Nach dem Refit auf 2015-2018 erfüllt das finale Modell alle zentralen Kriterien.

 **0.7566%**

sMAPE im Testjahr 2019

 **540.7 MW**

RMSE im Testjahr 2019

 **412.9 MW**

MAE im Testjahr 2019

 **Testfazit**

$R^2 = 0.9970$ und 91.0115% niedrigere sMAPE als die 24-Stunden-Persistenz.

Fehleranalyse und Limitationen

Die Jahreskennzahl ist stark, aber operative Einschränkungen bleiben wichtig.

- Mittlerer Bias: `-13.6282 MW`
- Höchster Monatsfehler: Dezember mit `0.9061%` sMAPE
- Fehler steigen besonders während der Morgenrampe
- Wochenenden: `0.8561%` sMAPE gegenüber `0.7169%` an Werktagen



Live-Demo im Notebook

[004_C_Phase.ipynb](#) - "Selected model residual distribution on 2019 test year"

K - Wissenstransfer

Das Projekt wird von der Analyse in eine nutzbare Szenarioanwendung übertragen.



Pipeline

Gleiche Lag-Feature-Struktur wie in der Modellbewertung.



Reproduktion

Die App-Pipeline reproduziert die 2019-Metriken innerhalb enger Toleranzen.



Nutzung

Lokaler Start mit `uv run streamlit run app/streamlit_app.py` .
([005 K Phase.ipynb](#))

Streamlit-Szenarioanwendung

Die Anwendung erstellt Zukunftsszenarien für Zeitpunkte von 2020 bis 2030.

- Startdatum, Startstunde und Prognosehorizont wählbar
- Prognosehorizonte: 24 Stunden, 48 Stunden, 7 Tage oder 30 Tage
- Szenarioannahmen für Nachfragewachstum, Temperatur und erneuerbare Erzeugung
- Tabs: `Scenario Forecast`, `Generated Inputs`, `Assumptions`



Live-Demo der App

[EnergyCast-App](#)

Fazit und nächste Schritte

EnergyCast zeigt eine stabile, reproduzierbare Lastprognose mit klaren nächsten Schritten.



Kernaussage

Das finale Modell unterschreitet die 5%-Schwelle deutlich und schlägt alle Baselines.

- Operativen Prognosehorizont explizit definieren
- Live-Lastdaten, Wetterprognosen und Prognosen zur erneuerbaren Erzeugung anbinden
- Messdaten nach 2019 zur externen Validierung ergänzen
- Optional dokumentierte Feiertags-Features hinzufügen

Vielen Dank

Name	Niklas Schneider
Matrikelnummer	...
Studiengang	Informatik
Modul	... - Data Analytics und Big Data